

古代玻璃制品的成分分析与鉴别

全国大学生数学建模竞赛参赛队

2022 年高教社杯 C 题

摘 要

古代玻璃在埋藏环境中易发生风化，成分比例随之改变，给类型鉴别带来困难。本文基于附件中 58 件文物的基本信息与 69 个化学成分采样点，在成分累加和 85% ~ 105% 的有效性约束下，建立风化关联分析、风化前成分还原、类型判别与亚类划分、未知样品鉴别及成分关联比较的完整模型体系。

问题一采用列联表与 Cramer's V 度量表面风化关联；对 2×2 表用 Fisher 精确检验，对稀疏多分类表用固定边际置换，避免小期望频数使渐近 χ^2 失真。成分比较先将同一文物、同一风化状态的重复点合并，再用 Mann-Whitney U 检验和 Benjamini-Hochberg FDR。风化前还原在 CLR 空间估计分类型平均位移并作小样本收缩，保证结果满足成分几何。

问题二以可解释阈值、决策树及“随机森林 + CLR-Logistic”集成模型提炼分类规律。所有验证均按文物编号分组留一，阈值也只在每一折训练集内选择，从源头阻断同一文物多点跨折泄漏。亚类发现先校正平均风化位移，再在文物级 CLR 标准化空间用 Ward 法聚类，簇数完全由轮廓系数与最小簇规模决定，不人为偏好某个 k 。

问题三用集成模型对表单 3 的 8 件未知样品鉴别，并与嵌套验证过的阈值规则交叉印证：A1、A6、A7 为高钾，其余为铅钡。模型输出称为“支持度”而非未经校准的概率；同时用文物级 bootstrap 区间、测量扰动翻转率和 CLR 最近邻适用域共同量化不确定性。

问题四以文物为独立分析单元，用控制风化状态后的比例协调系数 ρ 描述成分关联，并保留原始 Spearman 作为敏感性对照。类别差异通过“风化层内整体置换类型标签、每次重算完整关联矩阵”检验；结果支持两类总体关联结构不同 ($p = 0.002$)，FDR 校正后有 8 对成分表现出类别差异。

关键字：成分数据 分组验证 中心对数比变换 比例协调 分层置换 不确定性

目 录

一 问题重述	3
二 问题分析	3
三 模型假设与符号说明	4
3.1 模型假设	4
3.2 符号说明	5
四 数据预处理	5
五 问题一：风化关系、成分规律与风化前预测	5
5.1 风化与类型/纹饰/颜色的关联模型	5
5.2 分类型的有无风化成分统计规律	6
5.3 风化前化学成分预测模型	8
六 问题二：分类规律与亚类划分	9
6.1 高钾/铅钡分类规律	9
6.2 亚类划分方法	11
6.3 合理性与敏感性	12
七 问题三：未知样品鉴别	13
7.1 鉴别模型	13
7.2 敏感性分析	14
八 问题四：成分关联及其类别差异	15
8.1 组内关联模型	15
8.2 主要关联结论	16
8.3 类别间差异性	17
九 模型评价与推广	17
9.1 优点	17
9.2 不足与改进	17
9.3 推广	18
十 结论	18

参考文献	19
附录 支撑材料清单	20

一、问题重述

丝绸之路沿线出土的古代玻璃，外观可能与外来制品相近，但因助熔剂不同，化学成分存在本质差别。我国古代玻璃大体可分为高钾玻璃与铅钡玻璃两类。埋藏过程中的风化会使内部元素与环境元素大量交换，成分比例改变，从而干扰类型判断。

题目给出：表单 1（文物纹饰、类型、颜色、表面风化），表单 2（已分类样品 14 种氧化物含量），表单 3（8 件未知类别样品）。成分累加和介于 85% ~ 105% 的数据视为有效。需要解决：

1. 分析表面风化与类型、纹饰、颜色的关系；结合类型给出有无风化的成分统计规律，并由风化点预测风化前成分；
2. 提炼高钾/铅钡分类规律，对各类做亚类划分，并评估合理性与敏感性；
3. 鉴别表单 3 未知样品的类型，并做敏感性分析；
4. 分析不同类别成分关联关系，并比较两类之间的差异。

二、问题分析




图 1 两类玻璃在 PbO + BaO-K₂O 平面上的可解释分离（阈值仅在训练折内寻优）

问题一属于分类变量关联 + 成分对比 + 逆向还原。先在文物层面做列联分析，再在采样点层面按“类型 × 风化”分组比较 14 维成分，最后用组间风化系数把风化检测值映射回风化前状态。因无“风化前后成对”真值，还原结果应理解为同类型平均意义下

的校正，而非个体埋藏史的精确反演。

问题二是有监督分类规律提取 + 无监督亚类发现。分类侧强调可解释规则（阈值/决策树）并与集成模型对照；亚类侧需处理成分数据的定和约束，故先对未检出做成分自适应小值替换并闭合，再引入 CLR 变换后聚类，并用轮廓系数与扰动 ARI 评价。

问题三是迁移预测：用已标注样本训练分类器，输出模型支持度及 bootstrap 区间，再在与问题二一致的 CLR 标准化空间按亚类质心归属；同时用 PbO + BaO 阈值、输入扰动和适用域距离交叉核验。

问题四是成分关联及其组间差异。原始百分比相关会受定和约束和风化混杂影响，故以控制风化后的比例协调系数为主、Spearman 为对照，并用保持类型 × 风化构成的分层标签置换直接检验两类关联矩阵之差。

三、 模型假设与符号说明

3.1 模型假设

1. 空白（未检出）成分按 0 处理；累加和在 [85, 105] 内的采样点为有效数据。
2. 表单 2 中“严重风化点”视为风化，“未风化点”视为无风化；其余采样点风化属性与表单 1 一致。
3. 同一类型玻璃的风化过程具有统计上可迁移的平均规律，可用组间风化系数近似个体风化前成分；个体埋藏环境差异未观测，故预测为平均意义下的还原。
4. 风化主要改变各氧化物相对比例，检测误差相对风化效应为小量。
5. 亚类划分在给定类型内部进行，反映原料配比、工艺差异或风化程度差异，而非新的大类；小样本簇仅作候选亚型解释。
6. CLR 变换前，各成分零值用该成分最小正检出值的一半替换；该规则随检测尺度自适应，且只由训练数据估计。

3.2 符号说明

表 1 主要符号

符号	含义
x_{ij}	第 i 个采样点第 j 种成分含量 (%)
$\mathcal{C}$	14 种氧化物指标集合
$f_j^{(t)}$	类型 t 下成分 j 的风化系数
$\hat{x}_{ij}^{(0)}$	风化前成分预测值
$\text{clr}(\cdot)$	中心对数比变换
V	Cramer's V 关联系数
ARI	调整兰德指数
FDR	错误发现率 (Benjamini–Hochberg)

四、 数据预处理

对表单 2 空白填 0，计算成分总和

$$S_i = \sum_{j \in \mathcal{C}} x_{ij},$$

保留 $S_i \in [85, 105]$ 的样本。由“文物采样点”解析文物编号与特殊标记（部位 1/2、未风化点、严重风化点），并与表单 1 合并。空白记 0 而非均值填补，是因为题面明确“空白表示未检出”；若用均值填补会虚构“已检出”信息。

处理结果：69 个采样点中有效 67 个；无效点为编号 15、17（总和越界）。后续描述性图件保留采样点信息；凡涉及显著性、泛化性能或类别间比较，均以文物编号分组或先合并为文物级单元，避免重复采样导致伪增样本量。

五、 问题一：风化关系、成分规律与风化前预测

5.1 风化与类型/纹饰/颜色的关联模型

对因素 $A \in \{\text{类型, 纹饰, 颜色}\}$ 与表面风化做列联表，并报告 Cramer's V 。考虑纹饰和颜色表中存在较多期望频数小于 5 的单元格， 2×2 的“类型 $\times$ 风化”采用 Fisher 精确检验，其余采用固定边际的 9999 次标签置换；渐近 χ^2 仅保留为统计量：

$$\chi^2 = \sum_{u,v} \frac{(O_{uv} - E_{uv})^2}{E_{uv}}, \quad V = \sqrt{\frac{\chi^2}{n \cdot (\min(r, k) - 1)}}.$$

表 2 表面风化与各因素的关联检验

因素	χ^2	自由度	稳健 p 值	Cramer's V	样本量
类型	6.880	1	0.0113 (Fisher)	0.344	58
纹饰	4.957	2	0.1055 (置换)	0.292	58
颜色	6.287	7	0.5860 (置换)	0.341	54




图 2 表面风化与玻璃类型的关系

结论：风化与类型显著相关 ($p = 0.0113$, 中等效应); 稳健检验下纹饰 ($p = 0.1055$) 与颜色 ($p = 0.5860$) 均未达显著, 不能再把纹饰表述为“边缘显著”。铅钡玻璃风化比例更高, 但该结果是关联而非材料脆弱性的因果证明。

5.2 分类型的有无风化成分统计规律

对类型 $t \in \{\text{高钾, 铅钡}\}$, 先将同一文物、同一风化状态的重复采样取均值。编号 49、50 同时含风化与未风化点, 为避免在独立样本检验中重复计权, 将其留作风化位移估计但不进入 Mann–Whitney U 检验; 其余文物各贡献一个独立单元。对每一类型的 14 次检验分别采用 Benjamini–Hochberg 程序控制 FDR。用于描述的风化系数定义为

$$f_j^{(t)} = \frac{\bar{x}_{j,w}^{(t)}}{\bar{x}_{j,u}^{(t)}},$$

并用 bootstrap ($B = 1000$) 估计其 95% 置信区间。若某成分在两组中检出率均过低、系数极端 (> 8 或 ≤ 0) 或置信区间过宽, 则标记为不稳定, 预测阶段取 $f_j^{(t)} = 1$ (不校正), 避免稀有检出 (如 SO_2) 拉爆系数。




图 3 两类玻璃有无风化主要成分均值对比（右面板放大助熔/着色成分）




图 4 风化系数热图（色标为 $\log_2 f$ ，以 $f = 1$ 为中性；不稳定项掩码为“—”）

表 3 FDR 显著变化成分摘要 (FDR < 0.05)

类型	成分	无风化均值	风化均值	风化系数	变化方向
高钾	SiO ₂	67.77	93.96	1.39	显著升高
高钾	K ₂ O	9.57	0.54	0.06	显著流失
高钾	CaO	5.73	0.87	0.15	显著流失
高钾	MgO	1.05	0.20	0.19	显著流失
高钾	Al ₂ O ₃	6.41	1.93	0.30	显著流失
高钾	Fe ₂ O ₃	1.79	0.27	0.15	显著流失
铅钡	SiO ₂	56.35	27.22	0.48	显著下降
铅钡	CaO	1.07	2.42	2.25	显著升高
铅钡	PbO	20.78	43.82	2.11	显著富集
铅钡	P ₂ O ₅	0.67	4.50	6.73	显著富集

规律解读（化学含义）：

- **高钾玻璃**：风化使碱金属与碱土助熔剂大量淋失，SiO₂ 相对残留升高，表面呈现“高硅贫钾”。这与钾玻璃网络中可迁移阳离子易被地下水带走的机制一致。
- **铅钡玻璃**：硅酸盐网络破坏后，PbO、P₂O₅ 等在风化层相对富集，SiO₂ 反而下降。路径与高钾相反，说明两类玻璃不能共用同一套风化校正公式，必须**分类型**估计风化系数。

5.3 风化前化学成分预测模型

逐成分相除后再闭合并不遵守 **Aitchison 几何**，且零值会使比例爆炸。本文改在 CLR 空间估计类型 t 的平均风化位移

$$\delta^{(t)} = \lambda_t \left(\overline{\text{clr}(\mathbf{x})}_{w,t} - \overline{\text{clr}(\mathbf{x})}_{u,t} \right), \quad \lambda_t = \frac{n_{\text{eff}}}{n_{\text{eff}} + 4},$$

其中 λ_t 将小样本估计收缩到“无风化效应”。对风化点的还原为

$$\hat{\mathbf{x}}_i^{(0)} = \mathcal{C}_{S_i} [\exp(\text{clr}(\mathbf{x}_i) - \delta^{(t)})],$$

$\mathcal{C}_{S_i}$ 表示闭合到原检测总和 S_i 。描述性风化系数仍用于解释升降方向，但不再直接充当逆变换。




图 5 典型风化点：检测值与预测风化前成分对比

表 4 部分风化点风化前预测结果（%，节选）

采样点	类型	SiO ₂	K ₂ O	CaO	PbO	BaO	P ₂ O ₅
02	铅钡	62.28	1.22	1.00	23.06	0.40	0.51
07	高钾	80.65	1.68	3.49	0.12	0.67	1.40
09	高钾	84.21	3.41	2.06	0.13	0.68	0.82
08 严重风化点	铅钡	11.52	0.09	1.98	22.96	36.06	1.56

完整 32 个风化点预测见支撑材料 p1_predict_preweather.csv。需强调：该方法给出的是“若该点遵循同类型平均风化轨迹，其风化前成分应大致如何”，而非对单件文物埋藏史的唯一真值。

六、 问题二：分类规律与亚类划分

6.1 高钾/铅钡分类规律

以 14 维成分为特征，类型为标签。采用：

1. 深度受限决策树（可解释规则）；
2. 原始成分随机森林与 CLR-Logistic 的等权集成（降低单一模型偏差）；
3. 单指标阈值规则： $PbO + BaO \geq \tau$ 。

关键改进是验证单位。表单 2 含同一文物的多采样点，普通逐点留一会把同源信息同时放入训练集和验证集。本文使用 Leave-One-Group-Out，以文物编号为组；每一折的零值替换、标准化、模型拟合及阈值寻优均只使用训练文物。决策树（分组留一准确率

98.3%) 给出核心规则:

$$\begin{cases} \text{PbO} \leq 5.46 \Rightarrow \text{高钾}, \\ \text{PbO} > 5.46 \Rightarrow \text{铅钡}. \end{cases}$$

随机森林重要性排序前五为 BaO, PbO, SrO, SiO₂, K₂O。最终全训练集阈值为 $\tau^* = 8.655$ ；更重要的是，阈值在每一验证折内重新选择后仍取得 100% 的分组留一准确率，集成模型也为 100% (Brier 分数 0.0096)。这说明两类在该数据中分离很强，但由于样本少，100% 仅代表内部验证，不能外推为真实考古样本的无误差率。




图 6 分类规律：重要性与方法准确率对照




图 7 PbO + BaO 阈值判别（阴影为分区；标注了落在阈值右侧的高钾例外点）

图 7 显示两类在 PbO + BaO 轴上近乎线性可分。阈值图用于解释“铅钡助熔剂”这

一判别规律；正式未知样本鉴别仍由集成支持度、阈值一致性和适用域三项共同决定。

作为对照,标准化成分的PCA前两维累计方差约46.5%(PC1主载荷为BaO, SiO₂, PbO),只能作整体可分性示意,不宜单独作为分类依据。

6.2 亚类划分方法

成分数据满足定和约束,直接欧氏聚类易产生假结构。先将未检出替换为 ε ,再对选定成分向量 $\mathbf{x}$ 做CLR:

$$\text{clr}(\mathbf{x}) = \left(\ln \frac{x_1}{g(\mathbf{x})}, \dots, \ln \frac{x_p}{g(\mathbf{x})} \right), \quad g(\mathbf{x}) = \left(\prod_{j=1}^p x_j \right)^{1/p}.$$

为避免把“风化程度”误分成“工艺亚类”,先用问题一的分类型CLR位移校正所有风化点,再将同一文物多点取均值。在校正后的文物级CLR标准化空间使用Ward层次聚类;考虑高钾仅16件,最小簇规模设为2、搜索 $k=2,3$,铅钡最小簇规模设为3、搜索 $k=2,3,4$ 。完全按轮廓系数选型,不再人为偏好 $k=3$;亚类编号按SiO₂均值从高到低排列。

结果:高钾取 $k=2$ (14/2,轮廓系数0.341),铅钡取 $k=4$ (3/5/16/16,轮廓系数0.321)。与旧流程强行偏好 $k=3$ 相比,新结果更忠实反映数据:高钾的第二组仅2件,属于离群型候选组;铅钡存在中等偏弱的四组结构,其中 $n=3,5$ 的小组仍不可作确定工艺类型。




图8 亚类PCA可视化(含95%协方差椭圆)




图 9 各亚类关键成分均值对比

表 5 亚类质心（主要成分，%）与解释

类型	亚类	SiO ₂	<i>n</i>	关键特征	解释
高钾	亚类 1	74.37	14	K ₂ O 6.48, CaO 4.12	高钾主组
高钾	亚类 2	63.83	2	K ₂ O 13.40, CaO 8.25	低硅富钾钙离群组
铅钡	亚类 1	65.16	3	PbO 13.73, Al ₂ O ₃ 11.85	高硅高铝小样本组
铅钡	亚类 2	57.36	5	PbO 16.80, BaO 10.44	中硅低铅小样本组
铅钡	亚类 3	54.95	16	PbO 26.18, BaO 9.05	中硅中铅主组
铅钡	亚类 4	47.23	16	PbO 22.98, BaO 11.40	低硅富钡磷主组

风化校正后，铅钡旧分群中“某簇几乎全为风化点”的现象明显减弱；高钾主组含 8 个无风化、6 个风化文物，小组仅含 2 个无风化文物。平均校正降低了风化分层，却不能把 $n = 2$ 小组证实为真实工艺类别，因此只描述成分端元，不赋予产地语义。

6.3 合理性与敏感性

合理性用轮廓系数与校正后原空间方差削减比衡量。高钾方差削减比为 0.486、CLR 轮廓 0.341，但结果依赖仅 2 件的小组；铅钡方差削减比 0.335、轮廓 0.321，同样属于可讨论但不强的结构。

对成分施加相对高斯扰动 $x \leftarrow x(1 + \varepsilon)$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ，计算与原划分的 ARI。结果应结合均值和标准差解释：低扰动下较稳定，但随 σ 增大 ARI 下降且高钾波动明显，进一步说明小簇归属不应作确定结论。




图 10 亚类划分敏感性 (ARI- σ)




图 11 轮廓系数随 k 变化 (高钾 $k=2$, 铅钡 $k=4$)

七、 问题三：未知样品鉴别

7.1 鉴别模型

在文物分组验证通过后，用全训练集拟合“随机森林 +CLR-Logistic”集成，输出铅钡支持度

$$s(\mathbf{x}) = \frac{P_{\text{RF}}(\text{铅钡} | \mathbf{x}) + P_{\text{LR}}(\text{铅钡} | \text{clr}(\mathbf{x}))}{2}.$$

由于小样本下树投票和 Logistic 输出均未经过独立校准，本文不把 s 称为“真实概率”。以 $s \geq 0.5$ 判铅钡，并报告 200 次文物级 bootstrap 的 95% 区间和判别一致率。亚类归属先按预测类型校正风化位移，再在问题二同一 CLR 标准化空间取最近质心；这修复了“训练在 CLR 空间、预测却在原始百分比空间量距”的不一致。另用阈值规则及同类最近邻距离百分位交叉核验。




图 12 分类器可靠性与表单 3 预测

表 6 表单 3 未知样品鉴别结果

编号	表面风化	预测类型	阈值规则	高钾支持度	铅钡支持度	预测亚类
A1	无风化	高钾	高钾	0.962	0.038	高钾-亚类 1
A2	风化	铅钡	铅钡	0.255	0.745	铅钡-亚类 1
A3	无风化	铅钡	铅钡	0.094	0.906	铅钡-亚类 4
A4	无风化	铅钡	铅钡	0.082	0.918	铅钡-亚类 4
A5	风化	铅钡	铅钡	0.234	0.766	铅钡-亚类 1
A6	风化	高钾	高钾	0.979	0.021	高钾-亚类 1
A7	风化	高钾	高钾	0.977	0.023	高钾-亚类 2
A8	无风化	铅钡	铅钡	0.018	0.982	铅钡-亚类 4

依据与交叉印证: 集成模型与阈值规则对 8 件样品完全一致, 且 200 次文物 bootstrap 的类别一致率均为 1。A6、A7 的 $\text{SiO}_2 > 90\%$ 且几乎无 PbO/BaO , 符合风化高钾特征; A2–A5、A8 的 $\text{PbO} + \text{BaO}$ 高于阈值; A1 无铅钡成分, 判为高钾。A2 的适用域距离位于训练同类最近邻分布的 97.6% 分位, 略超预设 97.5% 边界, 因此其“铅钡”大类结论稳定, 但细亚类和支持度应谨慎解释。

7.2 敏感性分析

对输入施加 1% ~ 15% 相对高斯扰动并统计翻转率; 所有 8 件样品在各档扰动的 100 次重复中均未翻转。该结论只说明对设定的独立乘性检测误差稳定, 不覆盖系统偏

差、成分漏检机制改变或训练分布之外的新玻璃体系。



图 13 未知样品类别预测翻转率热图

八、 问题四：成分关联及其类别差异

8.1 组内关联模型

先在采样点层面校正分类型平均风化位移，再将同一文物的多点取均值；文物级风化标签取表单 1 的「表面风化」，避免编号 49、50 的风化/未风化点被多数票混成采样标签后再做层内置换。仅保留两类中检出率均不低于 20% 且有足够变异的成分。对零值作成分自适应替换并闭合后，令 $l_j = \log x_j$ ；在每一类型内再按风化状态减去组均值，以控制残余风化差异。主关联指标采用比例协调系数

$$\rho_{jk} = \frac{2 \operatorname{cov}(l_j, l_k)}{\operatorname{var}(l_j) + \operatorname{var}(l_k)}, \quad -1 \leq \rho_{jk} \leq 1.$$

ρ 接近 1 表示两成分近似按固定比例共同变化，接近 -1 表示对数尺度反向变化。对每对成分在风化层内置换其中一列 499 次得到 p 值并作 FDR 校正，另以 500 次文物 bootstrap 给出区间；原始 Spearman 只作为未处理定和约束和风化混杂的敏感性对照。




图 14 控制风化后的两类玻璃成分比例协调矩阵




图 15 两类玻璃主要比例协调对（按 $|\rho|$ Top8）

8.2 主要关联结论

- **高钾**：最强比例协调为 $\text{Fe}_2\text{O}_3\text{--CuO}$ ($\rho = 0.856$, bootstrap 95% CI [0.271, 0.944])；但组内成对置换经 FDR 后 $q = 0.072$ ，故只视为候选协同，不能写成已确认机制。FDR 显著的组内关联为 $\text{K}_2\text{O--BaO}$ ($\rho = -0.501$) 与 $\text{SiO}_2\text{--Al}_2\text{O}_3$ ($\rho = -0.262$)。
- **铅钡**： $\text{MgO--Al}_2\text{O}_3$ 呈稳健正向协调 ($\rho = 0.461$, CI [0.190, 0.700])； $\text{Al}_2\text{O}_3\text{--PbO}$ 呈反向协调 ($\rho = -0.458$, CI [-0.624, -0.168])； $\text{SiO}_2\text{--PbO}$ 亦呈反向协调 ($\rho = -0.405$, CI [-0.616, -0.189])，组内 FDR 分别为 0.0225、0.0225、0.045。
- **敏感性对照**：原始 Spearman 中若干“高硅-低助熔”强负相关在比例协调分析中明显减弱，说明旧结论主要混合了定和约束与风化组间差异；化学解释应以控制风化后的 ρ 为主。

8.3 类别间差异性

旧流程把相关矩阵上三角元素任意打乱，既未保持矩阵对称/半正定结构，也不对应 Mantel 的行列同步置换，因此原 $p = 0.161$ 无效。本文直接检验

$$T = \left\| \text{upper} \left(R_{\rho}^{\text{高钾}} - R_{\rho}^{\text{铅钡}} \right) \right\|_2.$$

在每个风化层内整体置换“类型”标签，保持类型 $\times$ 风化样本构成；每次重新残差化并计算两张完整矩阵。观察到 $T = 2.535$ ，999 次分层置换得 $p = 0.002$ ，支持两类总体关联结构存在差异。逐对差异再作 FDR，确认 8 对：SiO₂–PbO、SiO₂–BaO、K₂O–Al₂O₃、Al₂O₃–PbO、PbO–BaO、Fe₂O₃–CuO、CaO–CuO（均 $q = 0.0064$ ）以及 Al₂O₃–BaO（ $q = 0.017$ ）。




图 16 类别关联差异与原始相关敏感性对照

九、模型评价与推广

9.1 优点

1. 明确区分采样点与文物：推断使用文物级单元，验证按文物分组，消除了伪重复和跨折泄漏；
2. 风化还原、亚类距离和未知归属统一在 CLR 几何中完成，训练与预测空间一致；
3. 问题三同时报告 bootstrap、扰动和适用域；问题四使用保持实验结构的分层置换，结论均可复核。

9.2 不足与改进

1. 风化前预测仍是类型平均位移，缺少同一位置风化前后的真值；收缩只能降低方差，不能消除埋藏环境偏差；

2. 高钾文物数较少，亚类轮廓系数不高，亚类只能称为数据驱动候选组，不能直接解释为产地或工艺流派；
3. 模型支持度未在独立外部样本上校准；A2 略超训练适用域，需优先增加相似样本或人工复核；
4. 零值替换依赖“最小正检出值的一半”这一近似；若获得实验室检测限，应改用真实检测限及其不确定性。

9.3 推广

方法可迁移至陶瓷、青铜锈蚀产物等成分型文物分析：先做定和检验与风化校正，再用 CLR+ 聚类发现工艺亚型，最后以可解释分类器辅助考古鉴别。

十、 结论

1. Fisher/置换检验确认表面风化与玻璃类型相关 ($p = 0.0113$)，纹饰和颜色证据不足；分类型风化方向不同，CLR 收缩位移给出了满足成分性的平均还原。
2. PbO 与 BaO 是大类鉴别的核心指标；严格按文物分组并嵌套寻阈值后，阈值和集成模型在内部验证中均完全区分两类，但不把内部 100% 外推为普遍准确率。
3. 表单 3 中 A1、A6、A7 为高钾，A2、A3、A4、A5、A8 为铅钡；bootstrap 与扰动结论稳定，A2 因适用域距离偏高需谨慎。
4. 控制风化后的比例协调结构在两类间存在总体差异（分层置换 $p = 0.002$ ），FDR 确认 8 个差异成分对。

参考文献

参考文献

- [1] J. Aitchison. *The Statistical Analysis of Compositional Data*. Chapman & Hall, 1986.
- [2] L. Breiman. Random forests. *Machine Learning*, 45(5):5–32, 2001.
- [3] Y. Benjamini and Y. Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [4] 全国大学生数学建模竞赛组委会. 2022 高教社杯全国大学生数学建模竞赛题目 C 题. 2022.
- [5] D. Lovell, V. Pawlowsky-Glahn, J. J. Egozcue, S. Marguerat, and J. Bähler. Proportionality: A valid alternative to correlation for relative data. *PLoS Computational Biology*, 11(3):e1004075, 2015.

附录 支撑材料清单

- 代码: `code/solve_all.py`
- 结果表: `results/*.csv, *.json`
- 图件: `figures/*.png` (含方法对照图 `fig2_9_method_compare.png`)